(โครงร่างวิทยานิพนธ์)

ระบบตัวแทนสนทนาด้วยเสียงภาษาไทยเพื่อการเก็บรวบรวมข้อมูลผลการประเมินสุขภาพโดยผู้ป่วย

นายธีรวร อภิชนาพงศ์

วิทยานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิทยาศาสตรมหาบัณฑิต
สาขาวิชาวิทยาศาสตร์คอมพิวเตอร์ ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย
ปีการศึกษา 2569

ลิขสิทธิ์ของจุฬาลงกรณ์มหาวิทยาลัย

(THESIS PROPOSAL)

VOICE-BASED CONVERSATIONAL AGENT FOR COLLECTING THAI ELECTRONIC PATIENT-REPORTED OUTCOME MEASURES

Mr. Teeravorn Apichanapong

A Thesis Submitted in Partial Fulfillment of the Requirements

for the Degree of Master of Science Program in Computer Science

Department of Computer Engineering

Faculty of Engineering

Chulalongkorn University

Academic Year 2026

Copyright of Chulalongkorn University

หัวข้อวิทยานิพนธ์	(โครงร่างวิทยานิพนธ์) ระบบตัวแทนสนทนาด้วยเสียงภาษาไทยเพื่อการเก็บรวบรวมข้อมูลผลการประเมินสุขภาพโดยผู้ป่วย
โดย	นายธีรวร อภิชนาพงศ์
สาขาวิชา	วิทยาศาสตร์คอมพิวเตอร์
อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก	รองศาสตราจารย์ ดร. เกริก ภิรมย์โสภา

คณะวิศวกรรมศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย อนุมัติให้นับวิทยานิพนธ์ฉบับนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญามหาบัณฑิต

คณบดีคณะวิศวกรรมศาสตร์

. . . . . .

(รองศาสตราจารย์ ดร.วิทยา วัณณสุโภประสิทธิ์)

คณะกรรมการสอบวิทยานิพนธ์

. . . . . Chairman

( )

. . . . . อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

(รองศาสตราจารย์ ดร. เกริก ภิรมย์โสภา)

. . . . . External Examiner

( )

คำสำคัญ: ระบบการสนทนาด้วยเสียง / การรู้จำเสียงพูดอัตโนมัติ / การประมวลผลภาษาธรรมชาติ / มาตรวัดผลลัพธ์ที่ผู้ป่วยรายงาน

ธีรวร อภิชนาพงศ์: (โครงร่างวิทยานิพนธ์)

ระบบตัวแทนสนทนาด้วยเสียงภาษาไทยเพื่อการเก็บรวบรวมข้อมูลผลการประเมินสุขภาพโดยผู้ป่วย. ((Thesis Proposal)

Voice-Based Conversational Agent for Collecting Thai Electronic Patient-Reported Outcome Measures) อ.ที่ปรึกษาวิทยานิพนธ์หลัก : รศ. ดร. เกริก ภิรมย์โสภา, 33 หน้า.

การทำแบบสอบถามที่ผู้ป่วยกรอกเองมีข้อจำกัดด้านการเข้าถึง โดยเฉพาะสำหรับผู้สูงอายุและผู้ป่วยที่มีข้อจำกัดทางร่างกาย จึงจำเป็นต้องให้พยาบาลเป็นผู้สัมภาษณ์ ซึ่งต้องใช้บุคลากรและเวลามาก วิทยานิพนธ์นี้นำเสนอตัวแทนสนทนาด้วยเสียงภาษาไทยสำหรับเก็บข้อมูลผลลัพธ์ทางสุขภาพ ที่รายงานโดยผู้ป่วยในรูปแบบอิเล็กทรอนิกส์ เพื่อลดภาระของผู้ป่วยและบุคลากรทางการแพทย์ ระบบรองรับแบบประเมิน 3 แบบ ได้แก่ DASH และ TESS สำหรับรยางค์บนและรยางค์ล่าง โดยจะถามคำถามแต่ละข้อด้วยเสียงที่สร้างไว้ล่วงหน้าพร้อมภาพประกอบ แปลงคำตอบของผู้ป่วยเป็นข้อความด้วยระบบรู้จำเสียงพูดอัตโนมัติ และใช้แบบจำลองภาษาขนาดใหญ่ในการประมวลผลและจับคู่คำตอบกับตัวเลือกของแต่ละข้อ โดยทุกองค์ประกอบทำงานบนเซิร์ฟเวอร์ภายในเพื่อรักษาความเป็นส่วนตัวของข้อมูลผู้ป่วย และได้มีการประเมินความพร้อมสำหรับการใช้งานทางคลินิก ด้วยการวัดความสอดคล้องระหว่างคะแนนจากระบบกับคะแนนจากการสัมภาษณ์โดยพยาบาล ทั้งในระดับรายข้อและระดับคะแนนรวม

ภาควิชา	วิศวกรรมคอมพิวเตอร์	ลายมือชื่อนิสิต	.....
สาขาวิชา	วิทยาศาสตร์คอมพิวเตอร์	ลายมือชื่อ อ.ที่ปรึกษาหลัก	.....
ปีการศึกษา	2569		

6870141221: MAJOR COMPUTER SCIENCE
KEYWORDS: VOICE-BASED CONVERSATIONAL AGENT / AUTOMATIC SPEECH RECOGNITION / NATURAL LANGUAGE PROCESSING / PATIENT-REPORTED OUTCOME MEASURES

Teeravorn Apichanapong : (Thesis Proposal)

Voice-Based Conversational Agent for Collecting Thai Electronic Patient-Reported Outcome Measures. Advisor : Assoc. Prof. Krerk Piromsopa, Ph.D., 33 pp.

Self-administered questionnaires present accessibility limitations, particularly for elderly patients and those with physical impairments. Consequently, nurse-administered interviews are required, which demand substantial personnel and time. This thesis presents a Thai voice-based conversational agent for collecting electronic patient-reported outcomes (ePRO) to reduce the burden on both patients and health-care professionals. The system supports three assessment instruments: the Disabilities of the Arm, Shoulder and Hand (DASH) questionnaire and the Toronto Extremity Salvage Score (TESS) for the upper and lower extremities. Each item is presented through pre-generated speech accompanied by an illustration; the patient's spoken response is converted to text by automatic speech recognition (ASR), and a large language model (LLM) processes the transcript and maps it to the corresponding response option of the item. All components are deployed on a local server to preserve patient privacy. Readiness for clinical use is assessed by measuring the agreement between system-derived scores and those obtained from nurse-administered interviews at both the item and total-score levels.

Department:	Computer Engineering	Student's Signature .....
Field of Study:	Computer Science	Advisor's Signature .....
Academic Year:	2026	

กิตติกรรมประกาศ

สารบัญ

หน้า

บทคัดย่อภาษาไทย . . . . . ง

บทคัดย่อภาษาอังกฤษ . . . . . จ

กิตติกรรมประกาศ . . . . . ช

สารบัญ . . . . . ซ

สารบัญตาราง . . . . . ฌ

สารบัญภาพ . . . . . ญ

1 ที่มาและความสำคัญ 1

2 งานวิจัยและทฤษฎีที่เกี่ยวข้อง 2

2.1 ทฤษฎีที่เกี่ยวข้อง 2

2.2 งานวิจัยที่เกี่ยวข้อง 9

3 วัตถุประสงค์ 11

4 แนวคิดของงานวิจัยและวิธีการดำเนินงาน 11

4.1 แนวคิดของงานวิจัย 11

4.2 วิธีการดำเนินงาน 13

4.3 แผนการดำเนินงาน 14

4.4 การทดลองและการประเมินผล 15

5 ขอบเขตของงานวิจัย 16

6 ประโยชน์ที่คาดว่าจะได้รับ 17

รายการอ้างอิง **18**

ประวัติผู้เขียนวิทยานิพนธ์ **23**

สารบัญตาราง

ตารางที่ **หน้า**

1 เกณฑ์การแปลผลค่าสัมประสิทธิ์แคปปา [18] 8
2 เกณฑ์การแปลผลค่า ICC [17] 9
3 แผนการดำเนินงาน 14

สารบัญภาพ

รูปที่		หน้า
1	ตัวอย่างคำถามและตัวเลือกคำตอบของแบบประเมิน DASH ฉบับภาษาไทย	3
2	สถาปัตยกรรมของโมเดล Whisper [25]	4
3	สถาปัตยกรรมของโมเดล OmniVoice [34]	5
4	สถาปัตยกรรมแบบผสมของ Qwen3-Next ซึ่ง Qwen3.5 ใช้เป็นฐาน [22] . .	6
5	สถาปัตยกรรมของระบบที่นำเสนอ	12

1 ที่มาและความสำคัญ

มาตรวัดผลลัพธ์ที่รายงานโดยผู้ป่วย (Patient-Reported Outcome Measures: PROMs) เป็นเครื่องมือมาตรฐานสำหรับวัดสถานะสุขภาพและอาการจากมุมมองของผู้ป่วยโดยตรง และถูกนำไปใช้อย่างแพร่หลายในการติดตามผลการรักษาและการวิจัยทางคลินิก [3] ในสาขาออร์โธปิดิกส์ PROMs ที่ใช้ประเมินความสามารถเชิงหน้าที่ ได้แก่ Disabilities of the Arm, Shoulder and Hand (DASH) และ Toronto Extremity Salvage Score (TESS) ฉบับรยางค์บนและรยางค์ล่าง โดยทุกข้อคำถามมีตัวเลือกคำตอบเป็นมาตราส่วนเชิงอันดับ (ordinal scale) ที่มีคำบรรยายกำกับแต่ละระดับ

การเก็บข้อมูล PROMs มีสองรูปแบบหลัก ได้แก่ การให้ผู้ป่วยตอบแบบสอบถามด้วยตนเองทั้งบนกระดาษและในรูปแบบอิเล็กทรอนิกส์ (electronic PRO: ePRO) และการสัมภาษณ์โดยบุคลากรทางการแพทย์ การตอบแบบสอบถามด้วยตนเองเป็นอุปสรรคต่อผู้สูงอายุ ผู้ที่มีปัญหาด้านการมองเห็นหรือการอ่าน และผู้ป่วยที่มีความบกพร่องของรยางค์บน ซึ่งเป็นกลุ่มเป้าหมายของแบบประเมิน DASH และ TESS โดยตรง ผู้ป่วยกลุ่มนี้จึงต้องได้รับการสัมภาษณ์โดยพยาบาล ซึ่งต้องใช้บุคลากรและเวลาเป็นจำนวนมาก อีกทั้งรูปแบบการเก็บข้อมูลที่แตกต่างกันยังอาจส่งผลต่อคุณภาพของข้อมูล [4] ข้อจำกัดเหล่านี้เป็นอุปสรรคต่อการเก็บข้อมูล PROMs อย่างต่อเนื่องในเวชปฏิบัติ

ในช่วงหลายปีที่ผ่านมา เทคโนโลยีการรู้จำเสียงพูดอัตโนมัติ (Automatic Speech Recognition: ASR) [2, 30] และการสังเคราะห์เสียงพูด (Text-to-Speech: TTS) [21, 34] ได้รับการพัฒนาให้รองรับภาษาไทยได้ดีขึ้นอย่างต่อเนื่อง ประกอบกับโมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs) สามารถประมวลผลภาษาธรรมชาติได้อย่างมีประสิทธิภาพ [33, 29] ความก้าวหน้าดังกล่าวเอื้อต่อการพัฒนาตัวแทนสนทนา (conversational agent) ที่สื่อสารกับผู้ป่วยได้อย่างเป็นธรรมชาติ [19, 1] การเก็บข้อมูล PROMs ผ่านการสนทนาด้วยเสียงจึงเป็นแนวทางที่มีศักยภาพทั้งในการลดข้อจำกัดของการตอบแบบสอบถามด้วยตนเองและการลดภาระงานของบุคลากรทางการแพทย์

อย่างไรก็ตาม งานวิจัยส่วนใหญ่ที่ใช้ LLMs ในการเก็บข้อมูลสุขภาพผ่านการสนทนาใช้โมเดลที่ให้บริการผ่านระบบคลาวด์ เช่น ChatGPT ซึ่งก่อให้เกิดข้อกังวลด้านความเป็นส่วนตัวของข้อมูล เนื่องจากข้อมูลเสียงและข้อความของผู้ป่วยต้องถูกส่งไปประมวลผลบน

เซิร์ฟเวอร์ภายนอก นอกจากนี้ ระบบดังกล่าวยังให้โมเดลสร้างข้อความที่ใช้สื่อสารกับผู้ป่วยขึ้นระหว่างการสนทนา ทั้งการสร้างประโยคคำถามจากข้อคำถามในแบบประเมิน [6] และการสร้างข้อความอธิบายเพิ่มเติมเมื่อคำตอบกำกวม [12] จึงไม่สามารถควบคุมถ้อยคำที่ผู้ป่วยได้รับให้ตรงตามแบบประเมินต้นฉบับได้ทั้งหมด งานวิจัยนี้จึงมุ่งพัฒนาตัวแทนสนทนาด้วยเสียงภาษาไทยสำหรับเก็บรวบรวมข้อมูล ePRO โดยมีลักษณะสำคัญ 3 ประการ ดังนี้

1. ใช้แบบประเมิน DASH และ TESS ฉบับรยางค์บนและรยางค์ล่าง โดยคงถ้อยคำคำถามตามต้นฉบับ เพื่อรักษาความตรงของการวัด (measurement validity)
2. สื่อสารกับผู้ป่วยด้วยเสียงภาษาไทย โดยใช้ ASR และ TTS ทำงานร่วมกับโมเดลภาษาขนาดใหญ่
3. ประมวลผลทั้งหมดบนเซิร์ฟเวอร์ภายในของโรงพยาบาล เพื่อรักษาความเป็นส่วนตัวของข้อมูลผู้ป่วยและรองรับการใช้งานทางคลินิกได้อย่างปลอดภัย

2 งานวิจัยและทฤษฎีที่เกี่ยวข้อง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 มาตรวัดผลลัพธ์ที่รายงานโดยผู้ป่วยและแบบประเมิน DASH และ TESS

แบบประเมิน Disabilities of the Arm, Shoulder and Hand (DASH) พัฒนาขึ้นเพื่อวัดความบกพร่องและอาการของรยางค์บนจากมุมมองของผู้ป่วย [13] ส่วนแบบประเมิน Toronto Extremity Salvage Score (TESS) พัฒนาขึ้นเพื่อวัดความสามารถทางกายของผู้ป่วยเนื้องอกกระดูกและเนื้อเยื่ออ่อนภายหลังการผ่าตัดแบบสงวนรยางค์ โดยแยกเป็นฉบับรยางค์บนและรยางค์ล่าง [10] แบบประเมินทั้งสองมีลักษณะคล้ายกัน คือข้อคำถามส่วนใหญ่ถามถึงระดับความยากลำบากในการทำกิจกรรมในชีวิตประจำวัน และทุกข้อมีตัวเลือกคำตอบ 5 ระดับที่มีคำบรรยายกำกับ ดังรูปที่ 1

ทั้งนี้ DASH มีข้อคำถามส่วนหนึ่งที่ถามถึงความรุนแรงของอาการและผลกระทบต่อการทำงานและกิจกรรมทางสังคม [13] ส่วน TESS มีตัวเลือก “ไม่เกี่ยวข้อง” (not applicable) สำหรับกิจกรรมที่ผู้ป่วยไม่ได้ทำในชีวิตประจำวัน [10] คะแนนรายข้อ (1–5) ของทั้งสอง

DISABILITIES OF THE ARM, SHOULDER AND HAND ฉบับภาษาไทย

โปรดประเมินความสามารถของท่านเกี่ยวกับกิจกรรมต่อไปนี้ในช่วงอาทิตย์ที่ผ่านมา โดยวงกลมตัวเลขคำตอบที่เหมาะสม

	ไม่ยาก	ยากเล็กน้อย	ยากปานกลาง	ยากมาก	ทำไม่ได้เลย
1. เปิดฝาขวดที่ปิดแน่นหรือที่ยังไม่ถูกเปิดมาก่อน	1	2	3	4	5
2. เขียนหนังสือ	1	2	3	4	5
3. ไขกุญแจ	1	2	3	4	5
4. ทำอาหาร	1	2	3	4	5
5. ผลักประตูที่หนักให้เปิดออก	1	2	3	4	5
6. เอาของวางบนชั้นที่สูงเหนือศีรษะ	1	2	3	4	5
7. ทำงานบ้านหนักๆ (เช่น ขัดห้องน้ำ, ถูพื้น)	1	2	3	4	5
8. ทำสวนหรืองานสนาม เช่น ตัดหญ้า กวาดใบไม้	1	2	3	4	5

รูปที่ 1: ตัวอย่างคำถามและตัวเลือกคำตอบของแบบประเมิน DASH ฉบับภาษาไทย

แบบประเมินจะถูกแปลงเป็นคะแนนรวมในช่วง 0–100 โดยคะแนนของ DASH คำนวณตามสมการที่ (1) และต้องตอบอย่างน้อย 27 จาก 30 ข้อจึงจะคำนวณคะแนนได้ [15]

$$\text{DASH} = \left(\frac{1}{n} \sum_{i=1}^{n} (x_i) - 1 \right) \times 25 \tag{1}$$

ส่วนคะแนน TESS คำนวณตามสมการที่ (2) โดยไม่นำข้อที่ตอบว่าไม่เกี่ยวข้องมาคำนวณ [7]

$$\text{TESS} = \frac{\sum_{i=1}^{n} (x_i) - n}{4n} \times 100 \tag{2}$$

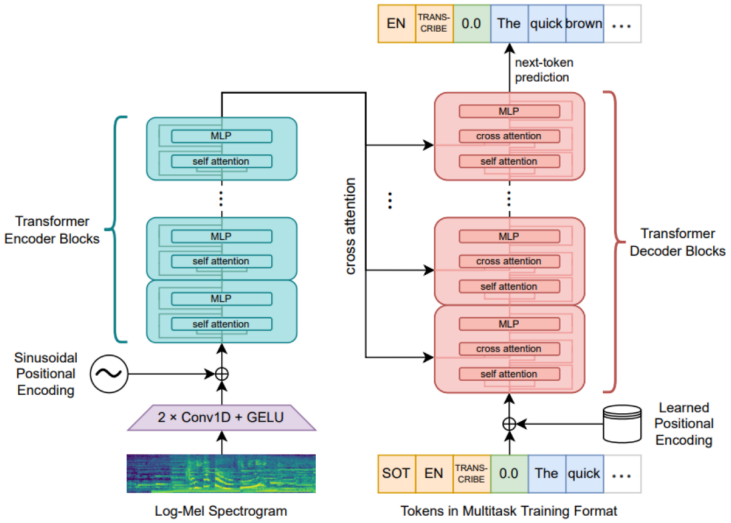
โดยที่ x_i คือคะแนนของข้อที่ i และ n คือจำนวนข้อที่ตอบ คะแนน DASH ที่สูงหมายถึงความบกพร่องมาก ในขณะที่คะแนน TESS ที่สูงหมายถึงความสามารถทางกายที่ดี

แบบประเมินทั้งสองมีฉบับภาษาไทยที่ผ่านการตรวจสอบความตรงและความเที่ยงแล้ว [5, 28] อย่างไรก็ตาม ผลการตรวจสอบนี้ใช้ได้กับแบบประเมินที่มีถ้อยคำและรูปแบบตามที่ใช้ในการตรวจสอบเท่านั้น การนำแบบประเมินไปใช้ในรูปแบบอิเล็กทรอนิกส์จึงต้องคงถ้อยคำคำถามและตัวเลือกคำตอบตามต้นฉบับ เพื่อรักษาความเท่าเทียมของการวัด (measurement equivalence) [9] งานวิจัยนี้จึงออกแบบระบบให้ถามข้อคำถามด้วยถ้อยคำตามต้นฉบับทุกครั้ง

2.1.2 การรู้จำเสียงพูดอัตโนมัติ

การรู้จำเสียงพูดอัตโนมัติ (Automatic Speech Recognition: ASR) คือการแปลงสัญญาณเสียงพูดเป็นข้อความ โมเดลที่ใช้อย่างแพร่หลายในปัจจุบัน ได้แก่ Whisper [25] ซึ่งเป็น Transformer แบบตัวเข้ารหัส-ตัวถอดรหัส (encoder-decoder) ที่รับสเปกโตรแกรม log-

Mel ของสัญญาณเสียงช่วงละ 30 วินาที และสร้างข้อความทีละโทเค็นแบบถดถอยในตัว (autoregressive) ดังรูปที่ 2



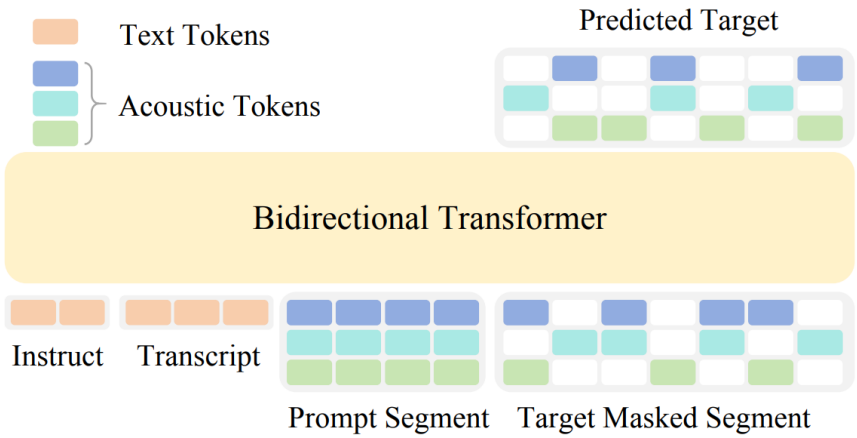
รูปที่ 2: สถาปัตยกรรมของโมเดล Whisper [25]

งานวิจัยนี้ใช้ Typhoon Whisper Turbo [30] ซึ่งปรับจูนจาก Whisper Large-v3 Turbo ที่ลดจำนวนชั้นของตัวถอดรหัสจาก 32 ชั้นเหลือ 4 ชั้น และมีพารามิเตอร์ประมาณ 809 ล้าน [20] โดยฝึกด้วยข้อมูลเสียงภาษาไทยประมาณ 11,000 ชั่วโมง ซึ่งข้อความถอดเสียงผ่านการปรับให้อยู่ในรูปคำอ่านมาตรฐาน (text normalization) เพื่อแก้ความกำกวมของการเขียนภาษาไทย เช่น ตัวเลขที่อ่านได้หลายแบบและไม้ยมก [27]

เนื่องจากภาษาไทยไม่มีการเว้นวรรคระหว่างคำ การวัดอัตราความผิดพลาดระดับคำจึงต้องตัดคำก่อน ASR ภาษาไทยจึงนิยมประเมินด้วยอัตราความผิดพลาดระดับอักขระ (Character Error Rate: CER) Typhoon Whisper Turbo มีค่า CER ร้อยละ 4.79 บนชุดข้อมูลเสียงทั่วไป Gigaspeech2 และร้อยละ 6.85 บนชุดข้อมูลเสียงที่มีสัญญาณรบกวน TVSpeech ใกล้เคียงกับ Typhoon Whisper Large-v3 ที่ฝึกด้วยข้อมูลชุดเดียวกัน (ร้อยละ 4.69 และ 6.32) [27] โมเดลจึงเหมาะกับการประมวลผลบนเซิร์ฟเวอร์ภายใน และเหมาะกับการถอดเสียงแบบออฟไลน์มากกว่าแบบต่อเนื่องตามเวลาจริง (streaming) [30] ซึ่งสอดคล้องกับระบบที่บันทึกคำตอบของผู้ป่วยทีละข้อก่อนถอดเสียง ทั้งนี้ ผลลัพธ์ของโมเดลอยู่ในรูปคำอ่าน เช่น “สิบ” แทน “10” [27] ซึ่งส่วนตีความคำตอบต้องรองรับ

2.1.3 การสังเคราะห์เสียงพูด

การสังเคราะห์เสียงพูด (Text-to-Speech: TTS) คือการแปลงข้อความเป็นเสียงพูด OmniVoice [34] เป็นโมเดล TTS แบบ zero-shot ที่รองรับมากกว่า 600 ภาษา รวมถึงภาษาไทย โดยใช้ Transformer แบบสองทิศทาง (bidirectional) แปลงข้อความเป็นโทเค็นเสียงโดยตรงแบบไม่ถดถอยในตัว (non-autoregressive) ดังรูปที่ 3 โมเดลถูกฝึกด้วยข้อมูลเสียงจากแหล่งเปิด 581,000 ชั่วโมง ซึ่งเป็นภาษาไทยประมาณ 10,500 ชั่วโมง และเสียงภาษาไทยที่สร้างขึ้นมีค่า CER ร้อยละ 1.23 บนชุดทดสอบ FLEURS ใกล้เคียงกับเสียงจริง (ร้อยละ 1.45) [34]



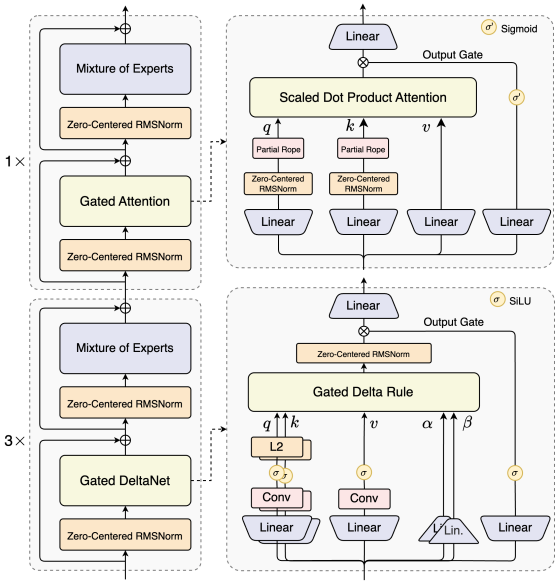
รูปที่ 3: สถาปัตยกรรมของโมเดล OmniVoice [34]

งานวิจัยนี้ใช้ OmniVoice สร้างเสียงคำถาม เสียงขอให้ตอบใหม่ และเสียงอ่านตัวเลือกไว้ล่วงหน้า และตรวจฟังก่อนนำไปใช้ เพื่อให้ผู้ป่วยทุกคนได้ยินถ้อยคำและการออกเสียงเดียวกัน

2.1.4 โมเดลภาษาขนาดใหญ่ Qwen3.5

Qwen3.5 [23] เป็นโมเดลภาษาขนาดใหญ่แบบเปิดเผยค่าน้ำหนัก (open-weight) ที่รับข้อมูลได้ทั้งข้อความและภาพ และรองรับ 201 ภาษา รวมถึงภาษาไทย โดยมีแบบหนาแน่น (dense) ขนาด 0.8-27 พันล้านพารามิเตอร์ จึงเลือกขนาดให้เหมาะกับเซิร์ฟเวอร์ภายในได้ และเลือกเปิดหรือปิดโหมดคิด (thinking mode) สำหรับการให้เหตุผลหลายขั้นตอนผ่านพารามิเตอร์ของแม่แบบการสนทนา [24]

Qwen3.5 ใช้สถาปัตยกรรมของ Qwen3-Next [23, 22] ดังรูปที่ 4 ซึ่งเป็น Transformer แบบตัวถอดรหัส (decoder-only) ที่ผสมกลไกความสนใจ 2 แบบในอัตราส่วน 3:1 แบบแรกคือ Gated DeltaNet ซึ่งเป็นความสนใจเชิงเส้น (linear attention) และแบบที่สองคือ Gated Attention ซึ่งเป็นความสนใจมาตรฐานที่เพิ่มเกตที่ผลลัพธ์ (output gate) การผสมทั้งสองแบบให้ทั้งประสิทธิภาพและความเร็วสูงกว่าการใช้แบบใดแบบหนึ่ง นอกจากนี้ยังใช้ Zero-Centered RMSNorm เพื่อเพิ่มเสถียรภาพของการฝึก [22]



รูปที่ 4: สถาปัตยกรรมแบบผสมของ Qwen3-Next ซึ่ง Qwen3.5 ใช้เป็นฐาน [22]

โมเดลภาษาขนาดใหญ่สร้างข้อความทีละโทเค็นแบบถดถอยในตัว โดยในแต่ละขั้นจะคำนวณความน่าจะเป็นของทุกโทเค็นในคลังคำศัพท์ แล้วเลือกโทเค็นถัดไปจากการแจกแจงดังกล่าว ผลลัพธ์จึงอาจมีรูปแบบไม่ตรงตามที่โปรแกรมต้องการ การถอดรหัสแบบมีข้อจำกัด (constrained decoding) แก้ปัญหานี้โดยกำหนดรูปแบบผลลัพธ์ด้วยโครงสร้างข้อมูล เช่น JSON schema แล้วในแต่ละขั้นจะตัดโทเค็นที่ทำให้ผลลัพธ์ผิดรูปแบบออกก่อนเลือกโทเค็นถัดไป ผลลัพธ์จึงอยู่ในรูปแบบที่กำหนดเสมอ [32] และวิธีนี้ช่วยให้โมเดลทำงานที่ต้องการผลลัพธ์แบบมีโครงสร้างได้โดยไม่ต้องปรับจูน [11]

2.1.5 ตัวชี้วัดสำหรับการประเมินผล

ตัวชี้วัดในงานวิจัยนี้ใช้ประเมินผลการจับคู่คำตอบเข้ากับระดับคะแนนใน 2 ระดับ ระดับแรกคือระดับรายข้อ ซึ่งเทียบระดับคะแนนที่ระบบเลือกกับระดับคะแนนอ้างอิง ได้แก่ ระดับคะแนนเป้าหมายของข้อมูลสังเคราะห์หรือคะแนนที่พยาบาลให้ ระดับที่สองคือระดับ

คะแนนรวม ซึ่งเทียบคะแนนรวมที่คำนวณจากคะแนนรายข้อของระบบกับคะแนนรวมที่คำนวณจากคะแนนอ้างอิงด้วยสูตรเดียวกัน ตัวชี้วัดระดับรายข้อมี 2 ตัว ได้แก่ accuracy และ weighted kappa ซึ่งตัวที่สองชดเชยข้อจำกัดของตัวแรก ส่วนตัวชี้วัดระดับคะแนนรวมมี 1 ตัว ได้แก่ intraclass correlation coefficient

ความถูกต้อง (accuracy) คือตัวชี้วัดพื้นฐานของงานจำแนกประเภท (classification) ซึ่งวัดสัดส่วนของตัวอย่างที่โมเดลทำนายประเภทตรงกับประเภทอ้างอิง ดังสมการที่ (3)

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{N_{\text{correct}}}{N} \tag{3}$$

โดยที่ N_{correct} คือจำนวนตัวอย่างที่ทำนายถูก และ N คือจำนวนตัวอย่างทั้งหมด ค่าความถูกต้องอยู่ในช่วง 0–1 และแปลผลได้ง่าย แต่มีข้อจำกัด 2 ข้อ ข้อแรก ค่าความถูกต้องนับการทำนายผิดทุกกรณีเท่ากัน จึงไม่เหมาะกับประเภทที่มีลำดับ (ordinal) ซึ่งการทำนายผิดไปยังลำดับที่อยู่ติดกันควรถือว่าผิดน้อยกว่าการทำนายผิดไปยังลำดับที่อยู่ห่างออกไป ข้อที่สองค่าความถูกต้องอาจสูงเกินจริงเมื่อจำนวนตัวอย่างของแต่ละประเภทไม่สมดุล (class imbalance) เนื่องจากโมเดลที่ทำนายประเภทที่พบบ่อยที่สุดทุกครั้งก็ได้ค่าความถูกต้องสูงได้ โดยไม่ได้แยกแยะประเภทเลย

ค่าสัมประสิทธิ์แคปปาแบบถ่วงน้ำหนัก (weighted kappa) คือสถิติที่ Cohen เสนอ [8] เพื่อวัดความสอดคล้องระหว่างผู้ให้คะแนน 2 ฝ่าย (inter-rater agreement) สำหรับข้อมูลเชิงอันดับ (ordinal data) เช่น การให้คะแนนระดับ 1 ถึง 5 ค่านี้ชดเชยข้อจำกัดทั้งสองประการของค่าความถูกต้อง กล่าวคือ ให้น้ำหนักความไม่สอดคล้องตามระยะห่างระหว่างระดับ และหักส่วนที่สอดคล้องกันโดยบังเอิญออก ดังสมการที่ (4)

$$\kappa_w = 1 - \frac{\sum_{i=1}^{C}\sum_{j=1}^{C} w_{ij}\, o_{ij}}{\sum_{i=1}^{C}\sum_{j=1}^{C} w_{ij}\, e_{ij}}, \qquad w_{ij} = \frac{(i-j)^2}{(C-1)^2} \tag{4}$$

โดยที่

- C คือจำนวนระดับคะแนน
- o_{ij} คือสัดส่วนของตัวอย่างที่ฝ่ายที่ 1 ให้ระดับ i และฝ่ายที่ 2 ให้ระดับ j ที่สังเกตได้จริง
- e_{ij} คือสัดส่วนที่คาดหวังโดยบังเอิญของกรณีเดียวกัน ซึ่งเท่ากับสัดส่วนที่ฝ่ายที่ 1 ให้ระดับ i คูณกับสัดส่วนที่ฝ่ายที่ 2 ให้ระดับ j

- w_{ij} คือน้ำหนักความไม่สอดคล้อง ซึ่งเท่ากับ 0 เมื่อทั้งสองฝ่ายให้ระดับเดียวกัน และเพิ่มขึ้นตามระยะห่างระหว่างระดับจนเท่ากับ 1 เมื่อให้ระดับที่อยู่คนละปลายของมาตราส่วน

ตัวเศษของสมการจึงแทนความไม่สอดคล้องที่เกิดขึ้นจริง และตัวส่วนแทนความไม่สอดคล้องที่คาดว่าจะเกิดขึ้นโดยบังเอิญ ค่า κ_w เท่ากับ 1 เมื่อสอดคล้องกันทั้งหมด เท่ากับ 0 เมื่อสอดคล้องกันเท่ากับที่คาดหวังโดยบังเอิญ และติดลบเมื่อสอดคล้องกันน้อยกว่าที่คาดหวังโดยบังเอิญ โดยแปลผลตามเกณฑ์ของ Landis and Koch [18] ดังตารางที่ 1

ค่า κ_w	**ระดับความสอดคล้อง**
น้อยกว่า 0.00	ต่ำกว่าการสุ่ม
0.00–0.20	น้อยมาก
0.21–0.40	พอใช้
0.41–0.60	ปานกลาง
0.61–0.80	มาก
0.81–1.00	เกือบสมบูรณ์

ตารางที่ 1: เกณฑ์การแปลผลค่าสัมประสิทธิ์แคปปา [18]

ค่าสัมประสิทธิ์สหสัมพันธ์ภายในชั้น (intraclass correlation coefficient: ICC) คือสถิติที่วัดความสอดคล้องของข้อมูลต่อเนื่องระหว่างผู้วัดตั้งแต่ 2 รายขึ้นไป โดยพิจารณาว่าความแปรปรวนของค่าที่วัดได้เกิดจากความแตกต่างระหว่างหน่วยที่ถูกวัด (subject) มากน้อยเพียงใด เมื่อเทียบกับความแปรปรวนทั้งหมด ดังสมการที่ (5)

$$\text{ICC} = \frac{\sigma_s^2}{\sigma_s^2 + \sigma_r^2 + \sigma_e^2} \tag{5}$$

โดยที่

- σ_s^2 คือความแปรปรวนระหว่างหน่วยที่ถูกวัด
- σ_r^2 คือความแปรปรวนระหว่างผู้วัด
- σ_e^2 คือความแปรปรวนของความคลาดเคลื่อน

ค่า ICC อยู่ในช่วง 0–1 และเข้าใกล้ 1 เมื่อความแปรปรวนส่วนใหญ่เกิดจากความแตกต่างระหว่างหน่วยที่ถูกวัด ซึ่งหมายความว่าผู้วัดทุกรายให้ค่าแก่หน่วยที่ถูกวัดแต่ละหน่วยใกล้เคียงกัน ICC มีหลายชนิดตามโมเดลทางสถิติ ชนิดของความสอดคล้อง และรูปแบบของค่าที่ใช้ ซึ่งให้ค่าแตกต่างกันจากข้อมูลชุดเดียวกัน จึงต้องเลือกชนิดให้เหมาะกับวัตถุประสงค์ของการวัดและระบุชนิดที่ใช้ทุกครั้ง [17] และแปลผลจากช่วงความเชื่อมั่นร้อยละ 95 ตามเกณฑ์ในตารางที่ 2

ในงานวิจัยนี้ หน่วยที่ถูกวัดคือผู้ป่วย ผู้วัดคือระบบและพยาบาล และค่าที่วัดคือคะแนนรวมของแบบประเมิน จึงใช้ ICC แบบสองทาง ชนิดความสอดคล้องสัมบูรณ์ (two-way, absolute agreement) แบบค่าเดี่ยว (single measure) ชนิดความสอดคล้องสัมบูรณ์นำความแตกต่างอย่างเป็นระบบระหว่างผู้วัดมาคิดด้วย จึงเหมาะกับการตรวจสอบว่าระบบให้คะแนนเท่ากับพยาบาล ไม่ใช่เพียงให้คะแนนเปลี่ยนแปลงไปในทิศทางเดียวกัน ส่วนแบบค่าเดี่ยวสอดคล้องกับการใช้งานจริงที่คะแนนมาจากระบบเพียงแหล่งเดียว

ค่า ICC	ระดับความสอดคล้อง
น้อยกว่า 0.50	ต่ำ
0.50–0.75	ปานกลาง
0.75–0.90	ดี
มากกว่า 0.90	ดีมาก

ตารางที่ 2: เกณฑ์การแปลผลค่า ICC [17]

2.2 งานวิจัยที่เกี่ยวข้อง

2.2.1 การเตรียมชุดข้อมูลบทสนทนาสำหรับการประเมิน PROMs

ในพัฒนาระบบ Chat-ePRO [6] ทางผู้วิจัยประสบปัญหาการขาดชุดข้อมูลในการ จึงใช้ ChatGPT สวมบทบาทแพทย์เสมือนและผู้ป่วยเสมือนสนทนากันตามข้อคำถามในแบบประเมิน ข้อคำถามแต่ละข้อนิยามเป็นเนื้อหาคำถามและชุดตัวเลือก โดยเพิ่มตัวเลือก “ไม่แน่ใจ” และ “ข้าม” เพื่อรองรับกรณีพิเศษ ผู้วิจัยสร้างบทสนทนาจากแบบประเมิน 3 ฉบับรวม 4,144 ชุด แล้วให้ผู้ตรวจสอบ 2 คนคัดกรองตามเกณฑ์ 5 ข้อ เช่น บทสนทนาต้องไม่ออกนอกเรื่อง เนื้อหาต้องไม่ขัดแย้งกันเอง และต้องไม่มีข้อมูลส่วนบุคคล คงเหลือ 3,965 ชุด และกลายเป็นชุดข้อมลูสังเคราะห์ที่ใช้สำหรับฝึกโมเดล

วิธีการที่สามารถนำมาปรับใช้ในการจัดทำชุดข้อมูลคำตอบภาษาไทยสำหรับแบบประเมิน DASH และ TESS จึงมีดังนี้

1. ใช้โมเดลภาษาขนาดใหญ่สวมบทบาทผู้ป่วยตอบข้อคำถามทีละข้อ โดยให้ตอบด้วยการบรรยายอาการหรือวิธีทำกิจกรรมแทนการระบุตัวเลือกโดยตรง และกำหนดระดับคะแนนเป้าหมายของคำตอบไว้ล่วงหน้าเพื่อใช้เป็น label

2. สร้างคำตอบในกรณีพิเศษ เช่น คำตอบที่กำกวมและกรณีที่ผู้ป่วยไม่ได้ทำกิจกรรมนั้น และควบคุมสัดส่วนของคำตอบแต่ละระดับให้สมดุล
3. คัดกรองข้อมูลที่สร้างขึ้นตามเกณฑ์ที่กำหนด และให้ผู้ตรวจสอบตรวจทาน label
4. ใช้ข้อมูลสังเคราะห์สำหรับการพัฒนาและเปรียบเทียบส่วนตีความคำตอบเท่านั้น ส่วนการประเมินขั้นสุดท้ายดำเนินการกับผู้ป่วยจริง เนื่องจากข้อมูลสังเคราะห์อาจมีการกระจายตัวแตกต่างจากข้อมูลจริง

2.2.2 การจัดการบทสนทนา (dialogue manager) สำหรับการเก็บข้อมูล PROMs

การใช้ GPT-3 ควบคุมตัวแทนสนทนาเก็บข้อมูลตามช่องข้อมูล (slot) ที่ระบุในคำสั่ง เก็บข้อมูลได้ร้อยละ 79 โดยช่องข้อมูลท้ายคำสั่งถูกข้ามบ่อยกว่าช่องข้อมูลต้นคำสั่ง และโมเดลไม่ได้ถามตามมาตราส่วนที่กำหนดเสมอ [31] และ ChatGPT สามารถติดตามสถานะของช่องข้อมูลได้แม่นยำต่ำกว่าโมเดลเฉพาะงาน (joint goal accuracy 0.27 เทียบกับ 0.60) แต่เมื่อได้รับสถานะที่ถูกต้อง อัตราความสำเร็จของบทสนทนาเพิ่มจาก 0.44 เป็น 0.68 [14] ส่วน CLARITY [26] เป็นระบบคัดกรองและส่งต่อผู้ป่วยที่ใช้เครื่องสถานะจำกัด (finite-state machine) ควบคุมบทสนทนา และใช้โมเดลภาษาขนาดใหญ่สร้างข้อความภายในแต่ละ state ระบบมีการใช้งานจริงกว่า 55,000 บทสนทนา และแนะนำแพทย์เฉพาะทางได้ถูกต้องในอันดับแรกร้อยละ 77

งานวิจัยนี้จึงออกแบบให้ข้อคำถามแต่ละข้อของแบบประเมินเป็นช่องข้อมูลหนึ่งช่อง และใช้ finite-state machine ในการติดตามสถานะและควบคุมลำดับการถามแทนโมเดล รวมถึงใช้เสียงที่สร้างไว้ล่วงหน้าแทนข้อความที่โมเดลสร้างขึ้น เพื่อไม่ให้ข้อคำถามถูกข้ามและคงถ้อยคำตามต้นฉบับ [9]

2.2.3 โมเดลภาษาขนาดใหญ่สำหรับการตีความคำตอบของผู้ป่วย

ระบบ Chat-ePRO [6] ใช้โมเดล BERT ที่ปรับจูนด้วยข้อมูลสังเคราะห์ที่ได้จากการให้ ChatGPT สวมบทบาทเป็นแพทย์และคนไข้ สกัดตัวเลือกจากบทสนทนา ได้ค่า Macro-F1 0.90-0.95 สูงกว่า ChatGPT แบบ few-shot ที่ได้ 0.75-0.81 HopeBot [12] ใช้ GPT-4o จัดคำตอบเข้ากับระดับของแบบประเมิน PHQ-9 และคำนวณคะแนนด้วยโปรแกรมที่แยกจากโมเดล เมื่อคำตอบกำกวมจะถามเพื่อขอความชัดเจน คะแนนจากระบบสอดคล้องกับการ

ตอบแบบประเมินด้วยตนเองที่ค่า ICC 0.92 ส่วนการเก็บแบบสำรวจทางโทรศัพท์ [16] ใช้ GPT-4o อนุมานคำตอบจากบทถอดความและบังคับรูปแบบของผลลัพธ์ ได้ความถูกต้องร้อยละ 98 แม้บทถอดความมีอัตราความผิดพลาดระดับคำร้อยละ 7.7 อย่างไรก็ตาม ทั้งสามงานใช้โมเดลที่ให้บริการผ่านระบบคลาวด์ ข้อมูลของผู้ป่วยจึงต้องถูกส่งออกนอกโรงพยาบาล ซึ่งไม่เหมาะกับข้อมูลสุขภาพตามพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 และผู้พัฒนา Chat-ePRO ระบุว่าเป็นอุปสรรคต่อการขยายผล [6]

งานวิจัยนี้จึงเลือกใช้โมเดลแบบ open-weight ที่เหมาะสมกับการทำงานบนเซิร์ฟเวอร์ภายใน โดยให้โมเดลเป็นตัวตีความคำตอบและเลือกตัวเลือกเท่านั้น ส่วนการคำนวณคะแนนของแบบประเมินและการจัดการบทสนทนาทำโดยส่วนอื่นของระบบ และกำหนดให้ผลลัพธ์ระบุทั้งระดับคะแนน ค่าความมั่นใจ และเจตนาของผู้ป่วย เพื่อใช้ตัดสินว่าจะถามผู้ป่วยอีกครั้งหรือไม่ ในกรณีที่คำตอบไม่ตรงกับตัวเลือกใด หรือคำตอบไม่ชัดเจน

3 วัตถุประสงค์

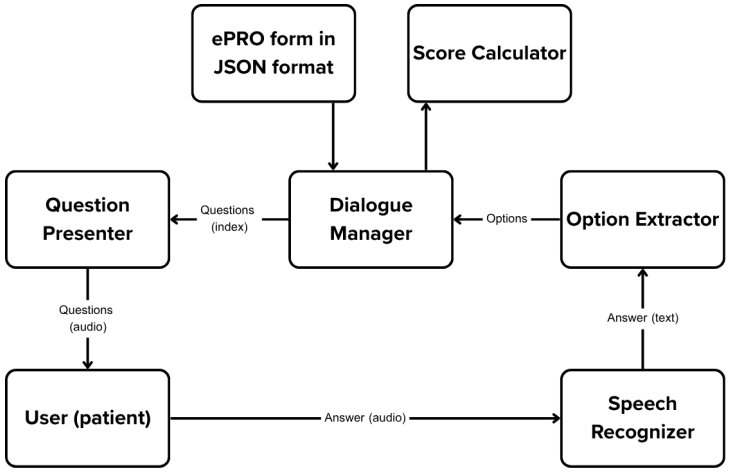
1. เพื่อออกแบบและพัฒนาระบบตัวแทนสนทนาด้วยเสียงภาษาไทยสำหรับเก็บรวบรวมข้อมูล ePRO ตามแบบประเมิน DASH และ TESS ฉบับรยางค์บนและรยางค์ล่าง โดยคงถ้อยคำคำถามตามแบบประเมินต้นฉบับ
2. เพื่อรักษาความเป็นส่วนตัวของผู้ป่วยและความปลอดภัยของข้อมูล โดยการพัฒนาตัวแทนสนทนาด้วยเสียงที่ทำงานบนเซิร์ฟเวอร์ภายในของโรงพยาบาล
3. เพื่อประเมินความสอดคล้องระหว่างคะแนนที่ได้จากตัวแทนสนทนากับคะแนนที่ได้จากการสัมภาษณ์โดยพยาบาลในผู้ป่วยจริง ทั้งในระดับรายข้อและระดับคะแนนรวม

4 แนวคิดของงานวิจัยและวิธีการดำเนินงาน

4.1 แนวคิดของงานวิจัย

แนวคิดหลักของงานวิจัยนี้คือการใช้ส่วนควบคุมบทสนทนาแบบ finite-state machine ในการควบคุมการสนทนากับผู้ป่วยตามแบบประเมินที่กำหนดไว้ล่วงหน้า โดยให้ผู้ป่วยตอบคำถามทีละข้อผ่านเสียงพูด และใช้ LLMs ในการตีความคำตอบของผู้ป่วยเพื่อจับคู่กับตัว

เลือกที่กำหนดไว้ในแบบประเมิน หลังจากผู้ป่วยตอบคำถามครบทุกข้อ ระบบจะคำนวณคะแนนรวมตามสูตรคำนวณของแบบประเมินที่ใช้และแสดงผลลัพธ์ให้ผู้ป่วยทราบ ซึ่งระบบที่นำเสนอประกอบด้วย 6 ส่วน ดังรูปที่ 5 และทุกองค์ประกอบทำงานบนเซิร์ฟเวอร์ภายในโรงพยาบาล โดยไม่มีการส่งข้อมูลเสียงหรือข้อความของผู้ป่วยไปยังบริการภายนอก



รูปที่ 5: สถาปัตยกรรมของระบบที่นำเสนอ

1. **ePRO Form (JSON Format)**: คือ ePRO ที่ถูกแปลงให้อยู่ในรูปแบบ JSON เรียบร้อยแล้ว ซึ่งโครงสร้างจะประกอบด้วยข้อคำถาม ระดับคำตอบเชิงอันดับพร้อมคำบรรยาย ไฟล์เสียงและภาพประกอบของแต่ละข้อ และประเภทของแบบประเมิน (DASH หรือ TESS) เพื่อให้สามารถนำไปงานต่อไปอย่างสะดวกและทำให้เพิ่มแบบประเมินใหม่ได้โดยไม่ต้องแก้ไขโปรแกรม

2. **Dialogue Manager**: ควบคุมบทสนทนาแบบ finite-state machine ที่จะเป็นตัวกำหนดลำดับการถามคำถาม และรับผลค่าความมั่นใจจาก option extractor หากค่าความมั่นใจของการจับคู่สูงกว่าเกณฑ์ ระบบจะบันทึกตัวเลือกและไปยังข้อถัดไป หากต่ำกว่าเกณฑ์ ระบบจะเล่นเสียงขอให้ตอบใหม่หรือเสียงอ่านตัวเลือกที่สร้างไว้ล่วงหน้า และเมื่อถามซ้ำครบจำนวนครั้งที่กำหนดแล้วยังไม่ได้คำตอบที่ชัดเจน จะบันทึกข้อนั้นไว้ให้พยาบาลตรวจสอบ

3. **Question Presenter**: เล่นเสียงคำถามที่ถูกสังเคราะห์ด้วย OmniVoice [34] และตรวจสอบไว้ล่วงหน้าแล้วพร้อมแสดงภาพประกอบ เพื่อให้ถ้อยคำคงที่และช่วยให้ผู้ป่วยเข้าใจคำถาม

4. **Speech Recognizer**: บันทึกเสียงคำตอบของผู้ป่วยทีละข้อ แล้วแปลงเป็นข้อความด้วยโมเดล Typhoon Whisper Turbo จากนั้นส่งข้อความไปยัง option extractor เพื่อจับคู่กับตัวเลือกของข้อคำถาม

5. **Option Extractor**: ทำการจับคู่ข้อความคำตอบเข้ากับระดับคะแนนของข้อคำถามด้วย Qwen3.5 โดยใช้ prompt ที่ระบุข้อคำถาม ตัวเลือกแต่ละระดับพร้อมคำบรรยายและคำตอบของผู้ป่วย แล้วให้โมเดลสร้างผลลัพธ์เป็น JSON ตาม schema ที่กำหนด ซึ่งประกอบด้วย 4 ส่วน ได้แก่ เหตุผลสั้น ๆ ที่อ้างอิงคำในคำตอบของผู้ป่วย ระดับคะแนนที่เลือก เจตนาของผู้ป่วยในกรณีที่ไม่ได้ตอบคำถาม เช่น ขอให้ทวนคำถามหรือไม่เข้าใจคำถาม และค่าความมั่นใจ ในระหว่างการสร้างผลลัพธ์จะใช้ constrained decoding บังคับให้ผลลัพธ์เป็นไปตาม schema และจำกัดระดับคะแนนให้อยู่ในชุดค่าของข้อคำถามนั้นเท่านั้น ส่งผลให้ผลลัพธ์อยู่ในรูปแบบที่โปรแกรมอ่านได้เสมอและไม่มีค่าที่อยู่นอกมาตราส่วน จากนั้นจึงส่งระดับคะแนน ค่าความมั่นใจ และเจตนาของผู้ป่วยให้ dialogue manager ดำเนินการต่อไป

6. **Score Calculator**: ทำการแปลงตัวเลือกรายข้อเป็นคะแนนและคำนวณคะแนนรวมตามสูตรของแบบประเมินแต่ละฉบับด้วยโปรแกรม เพื่อให้การคิดคะแนนเป็นไปตามแบบประเมินต้นฉบับและทำสามารถทำซ้ำได้

4.2 วิธีการดำเนินงาน

1. ศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้องกับ PROMs ตัวแทนสนทนาในทางการแพทย์ การรู้จำเสียงพูดภาษาไทย และการตีความคำตอบด้วยโมเดลภาษา

2. จัดทำแบบประเมิน DASH และ TESS ในรูปแบบโครงสร้างข้อมูล JSON และจัดทำเสียงคำถาม เสียงขอให้ตอบใหม่ เสียงอ่านตัวเลือก และภาพประกอบ

3. ออกแบบและพัฒนา dialogue manager แบบ finite-state machine และเชื่อมต่อกับ question presenter และ speech recognizer

4. จัดทำชุดข้อมูลคำตอบสังเคราะห์ภาษาไทยสำหรับการทดสอบ option extractor

5. พัฒนา option extractor ด้วย Qwen3.5 เลือกขนาดของโมเดล และทดสอบกับชุดข้อมูลสังเคราะห์เพื่อวัดความถูกต้องและประสิทธิภาพของโมเดล

6. บันทึกเสียงการสัมภาษณ์โดยพยาบาล และประเมิน option extractor กับคำตอบจริงของผู้ป่วย
7. integrate ระบบทั้งหมดเข้าด้วยกันและทดสอบการทำงานของระบบ
8. นำระบบไปใช้กับผู้ป่วยจริงและวัดเวลาที่พยาบาลใช้
9. วิเคราะห์ผล สรุปผลการวิจัย และจัดทำวิทยานิพนธ์

4.3 แผนการดำเนินงาน

แผนการดำเนินงาน	ส.ค.	ก.ย.	ต.ค.	พ.ย.	ธ.ค.	ม.ค.	ก.พ.
ศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง							
จัดทำแบบประเมิน DASH และ TESS ในรูปแบบ JSON รวมถึงไฟล์อื่นที่เกี่ยวข้อง							
ออกแบบและพัฒนา dialogue manager							
จัดทำชุดข้อมูลคำตอบสังเคราะห์ภาษาไทย							
พัฒนา option extractor และทดสอบกับข้อมูลสังเคราะห์							
บันทึกเสียงการสัมภาษณ์ และประเมิน option extractor							
integrate ระบบทั้งหมดเข้าด้วยกันและทดสอบ							
ทดลองใช้ระบบกับผู้ป่วยจริงควบคู่กับการสัมภาษณ์โดยพยาบาล							
วิเคราะห์ผล สรุปผลการวิจัย และจัดทำวิทยานิพนธ์							

ตารางที่ 3: แผนการดำเนินงาน

4.4 การทดลองและการประเมินผล

4.4.1 การทดลองที่ 1: การเลือกโมเดลสำหรับ Option Extractor

ทดสอบ option extractor กับชุดทดสอบของชุดข้อมูลคำตอบสังเคราะห์ โดยเปรียบเทียบ Qwen3.5 ขนาดต่าง ๆ ที่มีขนาดไม่เกิน 9 พันล้านพารามิเตอร์ ซึ่งเป็นขนาดที่ทำงานได้บนเซิร์ฟเวอร์ภายใน ทุกขนาดใช้ prompt และ schema เดียวกัน ปิดโหมดคิด และกำหนดค่าการสร้างข้อความให้คงที่ การทดลองนี้วัดผล 2 ด้าน ดังนี้

1. **ความถูกต้องและความสอดคล้องของการจับคู่** เทียบระดับคะแนนที่โมเดลเลือกกับระดับคะแนนเป้าหมายของข้อมูลสังเคราะห์ โดยวัดสัดส่วนของข้อที่เลือกระดับคะแนนตรงกันด้วย accuracy และวัด weighted kappa เพื่อประเมินความสอดคล้องของการจับคู่ที่คำนึงถึงระยะห่างของระดับคะแนน
2. **ทรัพยากรการคำนวณ** วัดเวลาที่ใช้ตีความคำตอบหนึ่งข้อ ภายใต้หน่วยความจำของหน่วยประมวลผลกราฟิก (GPU) ที่มีอยู่อย่างจำกัด

ผลการทดลองนี้ใช้เลือกขนาดของโมเดลที่สมดุลระหว่างความถูกต้องกับทรัพยากรการคำนวณ เพื่อนำไปใช้ในการทดลองที่ 2 และ 3

4.4.2 การทดลองที่ 2: ความสอดคล้องกับการสัมภาษณ์โดยพยาบาล

การทดลองนี้ประเมิน option extractor กับคำตอบจริงของผู้ป่วย โดยบันทึกเสียงระหว่างการสัมภาษณ์ตามแบบประเมินโดยพยาบาลตามขั้นตอนปกติ ทั้งเสียงคำถามของพยาบาลและเสียงคำตอบของผู้ป่วย และไม่บันทึกข้อมูลที่ระบุตัวตนของผู้ป่วย โดยที่จะใช้คะแนนรายข้อที่พยาบาลบันทึกระหว่างการสัมภาษณ์เป็นคะแนนอ้างอิง รวมถึงจับระยะเวลาที่ใช้ในการสัมภาษณ์ด้วย ซึ่งจะเก็บข้อมูลจากผู้ป่วยเป็นจำนวน 40 คน แบ่งเป็น 20 คนสำหรับแบบประเมิน DASH และ 20 คนสำหรับแบบประเมิน TESS

เสียงที่บันทึกจะถูกแบ่งเป็นช่วงตามข้อคำถาม โดยคำตอบของแต่ละข้อคือเสียงของผู้ป่วยตั้งแต่พยาบาลถามข้อนั้นจนถึงก่อนพยาบาลถามข้อถัดไป จากนั้นแปลงเป็นข้อความด้วย speech recognizer และจับคู่กับระดับคะแนนด้วย option extractor แล้ววัดความสอดคล้อง

กับคะแนนของพยาบาลในระดับรายข้อด้วย weighted kappa และในระดับคะแนนรวมด้วยค่า ICC โดยคำนวณแยกตามแบบประเมินแต่ละฉบับ

4.4.3 การทดลองที่ 3: การใช้งานระบบกับผู้ป่วยจริง

การทดลองนี้นำระบบทั้งหมดไปใช้เก็บข้อมูลกับผู้ป่วยจริง เพื่อประเมินว่าระบบช่วยลดเวลาที่พยาบาลต้องใช้ในการเก็บข้อมูลได้หรือไม่ โดยที่จะเก็บข้อมูลจากผู้ป่วยเท่ากับการทดลองที่ 2 เวลาที่บันทึกมี 2 ค่า ได้แก่

1. **เวลาที่ผู้ป่วยใช้กับระบบ** บันทึกโดยอัตโนมัติตั้งแต่เริ่มเล่นเสียงคำถามข้อแรกจนได้คำตอบของข้อสุดท้าย
2. **เวลาที่พยาบาลใช้ตรวจสอบ** บันทึกตั้งแต่พยาบาลเริ่มตรวจสอบข้อที่ระบบส่งให้ตรวจสอบจนยืนยันคะแนนครบ ซึ่งเป็นเวลาที่บุคลากรต้องใช้จริงเมื่อเก็บข้อมูลด้วยระบบ

5 ขอบเขตของงานวิจัย

1. แบบประเมินที่ใช้ในงานวิจัยนี้มี 3 ฉบับ ได้แก่ DASH ฉบับภาษาไทย และ TESS ฉบับภาษาไทยสำหรับรยางค์บนและรยางค์ล่าง
2. ระบบรองรับการสนทนาด้วยเสียงภาษาไทยและภาษาอังกฤษเท่านั้น
3. งานวิจัยนี้จะใช้โมเดลการรู้จำเสียงพูดและเสียงสังเคราะห์ที่มีอยู่แล้วและไม่ครอบ คลุมการพัฒนาหรือปรับปรุงโมเดลดังกล่าว
4. โมเดลทั้งหมดเป็นโมเดลที่เปิดเผยค่าน้ำหนัก (open-weight) และประมวลผลบนเซิร์ฟเวอร์ภายใน
5. การประเมินผลดำเนินการกับผู้ป่วยที่เข้ารับการรักษาในโรงพยาบาลที่ร่วมวิจัย โดยใช้คะแนนจากการสัมภาษณ์โดยพยาบาลเป็นค่าอ้างอิง
6. ระบบทำหน้าที่เก็บรวบรวมข้อมูลและให้คะแนนตามแบบประเมินเท่านั้น ไม่ได้ทำหน้าที่วินิจฉัยโรคหรือให้คำแนะนำทางการแพทย์

6 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้ระบบต้นแบบสำหรับเก็บรวบรวมข้อมูล ePRO ด้วยเสียงภาษาไทย ซึ่งช่วยลดภาระงานของบุคลากรทางการแพทย์ และเพิ่มการเข้าถึงสำหรับผู้ป่วยที่มีข้อจำกัดในการตอบแบบสอบถามด้วยตนเอง
2. ได้สถาปัตยกรรมที่แยกการควบคุมบทสนทนาออกจากการตีความคำตอบ ซึ่งรักษาความเป็นมาตรฐานของถ้อยคำคำถาม และขยายไปใช้กับแบบประเมินอื่นได้โดยเพิ่มเพียงไฟล์แบบประเมินในรูปแบบ JSON ที่กำหนด
3. ได้ผลการประเมินการใช้โมเดลภาษาขนาดใหญ่ที่ทำงานบนเซิร์ฟเวอร์ภายใน สำหรับจับคู่คำตอบภาษาพูดภาษาไทยเข้ากับมาตราส่วนเชิงอันดับ
4. ได้หลักฐานเกี่ยวกับความสอดคล้องระหว่างการประเมินโดยระบบกับการสัมภาษณ์โดยพยาบาล ซึ่งเป็นข้อมูลประกอบการพิจารณานำระบบไปใช้ในเวชปฏิบัติ

รายการอ้างอิง

[1] An, J., Yi, S., Lyu, Y., Liu, H., and Zhang, Y. 2025. Conversational agents for older adults' health: A systematic literature review. arXiv preprint arXiv:2503.23153 (2025):

[2] Aung, Z. H., Thavornmongkol, T., Boribalburephan, A., Tangsriworakan, V., Pipatsrisawat, K., and Achakulvisut, T. 2024. Thonburian Whisper: Robust fine-tuned and distilled Whisper for Thai. In Proceedings of the 7th International Conference on Natural Language and Speech Processing (ICNLSP 2024), pp. 149–156. : Association for Computational Linguistics.

[3] Black, N. 2013. Patient reported outcome measures could help transform healthcare. BMJ 346 (2013): f167.

[4] Bowling, A. 2005. Mode of questionnaire administration can have serious effects on data quality. Journal of Public Health 27.3 (2005): 281–291.

[5] Buntragulpoontawee, M., Phutrit, S., Tongprasert, S., Wongpakaran, T., and Khunachiva, J. 2018. Construct validity, test–retest reliability and internal consistency of the Thai version of the disabilities of the arm, shoulder and hand questionnaire (DASH-TH) in patients with carpal tunnel syndrome. BMC Research Notes 11.1 (2018): 208.

[6] Chen, Z., Wang, Q., Sun, Y., Cai, H., and Lu, X. 2024. Chat-ePRO: Development and pilot study of an electronic patient-reported outcomes system based on ChatGPT. Journal of Biomedical Informatics 154 (2024): 104651.

[7] CODE Technology 2025. Toronto extremity salvage score (TESS): Comprehensive guide to assessment & scoring. https://www.codetechnology.com/blog/toronto-extremity-salvage-score-tess-comprehensive-guide-to-assessment

[8] Cohen, J. 1968. Weighted kappa: nominal scale agreement provision for scaled disagreement or partial credit. Psychological Bulletin 70.4 (1968): 213–220.

[9] Coons, S. J., Gwaltney, C. J., Hays, R. D., Lundy, J. J., Sloan, J. A., Revicki, D. A., Lenderking, W. R., Cella, D., and Basch, E. 2009. Recommendations on evidence needed to support measurement equivalence between electronic and paper-based patient-reported outcome (PRO) measures: ISPOR ePRO Good Research Practices Task Force report. Value in Health 12.4 (2009): 419–429.

[10] Davis, A. M., Wright, J. G., Williams, J. I., Bombardier, C., Griffin, A., and Bell, R. S. 1996. Development of a measure of physical function for patients with bone and soft tissue sarcoma. Quality of Life Research 5.5 (1996): 508–516.

[11] Geng, S., Josifoski, M., Peyrard, M., and West, R. 2023. Grammar-constrained decoding for structured NLP tasks without finetuning. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, pp. 10932–10952. : Association for Computational Linguistics.

[12] Guo, Z., Lai, A., Ive, J., Petcu, A., Wang, Y., Qi, L., Thygesen, J. H., and Li, K. 2025. Development and evaluation of HopeBot: an LLM-based chatbot for structured and interactive PHQ-9 depression screening. arXiv preprint arXiv:2507.05984 (2025):

[13] Hudak, P. L., Amadio, P. C., and Bombardier, C. 1996. Development of an upper extremity outcome measure: the DASH (Disabilities of the Arm, Shoulder and Hand). American Journal of Industrial Medicine 29.6 (1996): 602–608.

[14] Hudeček, V. and Dušek, O. 2023. Are large language models all you need for task-oriented dialogue? In Proceedings of the 24th Annual Meeting of the Special Interest Group on Discourse and Dialogue, pp. 216–228. : Association for Computational Linguistics.

[15] Institute for Work & Health 2010. Scoring the DASH. https://dash.iwh.on.ca/sites/dash/files/downloads/dash_scoring_2010.pdf.

[16] Kaiyrbekov, K., Dobbins, N. J., and Mooney, S. D. 2025. Automated survey collection with LLM-based conversational agents. arXiv preprint arXiv:2504.02891 (2025):

[17] Koo, T. K. and Li, M. Y. 2016. A guideline of selecting and reporting intraclass correlation coefficients for reliability research. Journal of Chiropractic Medicine 15.2 (2016): 155–163.

[18] Landis, J. R. and Koch, G. G. 1977. The measurement of observer agreement for categorical data. Biometrics 33.1 (1977): 159–174.

[19] Laranjo, L., Dunn, A. G., Tong, H. L., Kocaballi, A. B., Chen, J., Bashir, R., Surian, D., Gallego, B., Magrabi, F., Lau, A. Y. S., and Coiera, E. 2018. Conversational agents in healthcare: a systematic review. Journal of the American Medical Informatics Association 25.9 (2018): 1248–1258.

[20] OpenAI 2024. Whisper large-v3-turbo. https://huggingface.co/openai/whisper-large-v3-turbo.

[21] Pipatanakul, K., Manakul, P., Nitarach, N., et al. 2024. Typhoon 2: A family of open text and multimodal Thai large language models. arXiv preprint arXiv:2412.13702 (2024):

[22] Qwen Team 2025. Qwen3-Next: Towards ultimate training & inference efficiency. https://qwen.ai/blog?id=4074cca80393150c248e508aa62983f9cb7d27cd.

[23] Qwen Team 2026. Qwen3.5: Towards native multimodal agents. https://qwen.ai/blog?id=qwen3.5.

[24] Qwen Team 2026. Qwen3.5-0.8B. https://huggingface.co/Qwen/Qwen3.5-0.8B.

[25] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., and Sutskever, I. 2023. Robust speech recognition via large-scale weak supervision. In Proceedings of the 40th International Conference on Machine Learning (ICML). :

[26] Shaposhnikov, V., Nesterov, A., Kopanichuk, I., Bakulin, I., Zhelvakov, E., Abramov, R., Tsapieva, E., Bespalov, I., Dylov, D. V., and Oseledets, I. 2025. CLARITY: Clinical assistant for routing, inference, and triage. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track, pp. 1805–1821. : Association for Computational Linguistics.

[27] Sirichotedumrong, W., Na-Thalang, A., Manakul, P., Taveekitworachai, P., Sripaisarnmongkol, S., and Pipatanakul, K. 2026. Typhoon ASR Real-time: FastConformer-Transducer for Thai automatic speech recognition. arXiv preprint arXiv:2601.13044 (2026):

[28] Srisawat, P., Ketsararat, W., Pairojboriboon, S., Veeraphun, P., Punyaratabandhu, T., Chareonvareekul, S., Songpatanasilp, T., and Pipithkul, S. 2018. Development, validation, and reliability of functional outcome questionnaire on Toronto Extremity Salvage Score [TESS] to Thai version for patients with bone and soft-tissue sarcoma. Journal of the Medical Association of Thailand 101.1 (2018): 97–102.

[29] Thirunavukarasu, A. J., Ting, D. S. J., Elangovan, K., Gutierrez, L., Tan, T. F., and Ting, D. S. W. 2023. Large language models in medicine. Nature Medicine 29.8 (2023): 1930–1940.

[30] Typhoon Team, SCB 10X 2026. Typhoon Whisper Turbo. `https://huggingface.co/typhoon-ai/typhoon-whisper-turbo`.

[31] Wei, J., Kim, S., Jung, H., and Kim, Y.-H. 2024. Leveraging large language models to power chatbots for collecting user self-reported data. Proceedings of the ACM on Human-Computer Interaction 8.CSCW1 (2024): 1–35.

[32] Willard, B. T. and Louf, R. 2023. Efficient guided generation for large language models. arXiv preprint arXiv:2307.09702 (2023):

[33] Yang, A. et al. 2025. Qwen3 technical report. arXiv preprint arXiv:2505.09388 (2025):

[34] Zhu, H., Ye, L., Kang, W., Yao, Z., Guo, L., Kuang, F., Han, Z., Zhuang, W., Lin, L., and Povey, D. 2026. OmniVoice: Towards omnilingual zero-shot text-to-speech with diffusion language models. arXiv preprint arXiv:2604.00688 (2026):

ประวัติผู้เขียนวิทยานิพนธ์

ชื่อ-สกุล	นายธีรวร อภิชนาพงศ์
วัน เดือน ปี เกิด	20/11/2540
สถานที่เกิด	กรุงเทพฯ
สถาบันที่ศึกษา	มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี, ปริญญาตรี (วิศวกรรมหุ่นยนต์และระบบอัตโนมัติ), 2562
ที่อยู่อาศัย	37/231 หมู่บ้านเลิศอุบล 4 ซ.นาคนิวาส 48 แยก 14-13 แขวงลาดพร้าว เขตลาดพร้าว กรุงเทพฯ 10230
ผลงานตีพิมพ์	A semi-automated system for person re-identification adaptation to cross-outfit and cross-posture scenarios